



**INSTITUTO FEDERAL DE EDUCAÇÃO CIÊNCIA E TECNOLOGIA DO  
TRIÂNGULO MINEIRO - Campus Ituiutaba  
CURSO SUPERIOR DE CIÊNCIA DA COMPUTAÇÃO**

**JOÃO PEDRO ARAUJO QUEIROZ BARBOSA**

**Inteligência Artificial no Auxílio ao Diagnóstico de Dermatologia: Um  
Estudo de Caso com Telegram Bot**

**ITUIUTABA, MG**

**2024**

**JOÃO PEDRO ARAUJO QUEIROZ BARBOSA**

**Inteligência Artificial no Auxílio ao Diagnóstico de Dermatologia: Um Estudo de Caso  
com Telegram Bot**

Projeto de trabalho de conclusão de curso  
apresentado ao Instituto Federal de Educação,  
Ciência e Tecnologia do Triângulo Mineiro,  
Campus Ituiutaba, como requisito parcial para  
conclusão do Curso de Bacharel em Ciência da  
Computação.

Orientador: Dr. André Luiz França Batista

**ITUIUTABA, MG**

**2024**

## **TERMO DE APROVAÇÃO**

**JOÃO PEDRO ARAUJO QUEIROZ BARBOSA**

Projeto de conclusão de curso apresentado ao Instituto Federal de Educação, Ciência e Tecnologia do Triângulo Mineiro, Campus Ituiutaba, como requisito parcial para obtenção do diploma de Bacharel em Ciência da Computação, sob a orientação do Prof. Dr. André Luiz França Batista.

Aprovado em \_\_\_\_\_ de \_\_\_\_\_ de \_\_\_\_\_

---

Prof. Dr. André Luiz França Batista (Prof. Orientador)

---

Prof. (Prof. Convidado)

---

Prof. (Prof. Convidado)

**ITUIUTABA, MG**

**2024**

SUMÁRIO

|          |  |          |
|----------|--|----------|
| <b>1</b> | <b>Introdução</b>  | <b>5</b> |
| <b>2</b> | <b>Objetivos</b>   | <b>6</b> |
| 2.1      | Desenvolvimento de um Sistema de Inteligência Artificial Preciso e Eficiente . | 6        |
| 2.2      | Implementação de uma Interface Acessível via Telegram Bot . . . . .            | 6        |
| 2.3      | Integração com Algoritmos Avançados de Machine Learning e Deep Learning .      | 6        |
| 2.4      | Avaliação da Eficiência e Precisão do Sistema . . . . .                        | 6        |
| 2.5      | Contribuição para a Democratização dos Cuidados Dermatológicos . . . . .       | 6        |
| <b>3</b> | <b>Referencial Teórico</b>   | <b>7</b> |
| 3.1      | Modelos de Deep Learning para Diagnóstico Médico . . . . .                     | 7        |
| 3.2      | Aplicação de Redes Neurais Convolucionais em Diagnósticos Dermatológicos .     | 8        |
| 3.3      | Validação e Avaliação de Modelos . . . . .                                     | 8        |
| <b>4</b> | <b>Metodologia</b>   | <b>9</b> |
| 4.1      | Descrição do conjunto de dados . . . . .                                       | 9        |
| 4.2      | Pré-processamento de dados . . . . .   | 9        |
| 4.3      | Desenvolvimento de Modelos . . . . .   | 9        |
| 4.4      | Escolha e justificativa dos algoritmos . . . . .                               | 10       |
| 4.5      | Avaliação do modelo . . . . .  | 10       |
| 4.6      | Implementação do Telegram Bot . . . . .  | 10       |

# 1 Introdução

As doenças de pele não apenas representam um desafio para os pacientes individualmente, mas também impõem um fardo significativo aos sistemas de saúde em todo o mundo. A prevalência dessas condições, aliada à complexidade de muitas delas, resulta em uma demanda crescente por serviços dermatológicos. No entanto, essa demanda nem sempre pode ser adequadamente atendida, devido a vários obstáculos, como a escassez de dermatologistas em determinadas regiões, especialmente em áreas remotas ou subdesenvolvidas.

Além disso, o diagnóstico dermatológico enfrenta desafios únicos, muitas vezes relacionados à subjetividade na interpretação das lesões cutâneas. A variedade de sintomas e a sobreposição entre diferentes condições dermatológicas podem dificultar a identificação precisa da doença, levando a diagnósticos errôneos ou atrasados. Essa falta de precisão pode ter consequências graves para os pacientes, resultando em tratamentos inadequados, progressão da doença e impacto negativo na qualidade de vida.

Nesse cenário, a inteligência artificial emerge como uma ferramenta promissora para superar esses desafios. Por meio da análise de grandes conjuntos de dados de imagens dermatológicas, os algoritmos de IA podem detectar padrões e características específicas das lesões que podem escapar à percepção humana. Com o avanço das técnicas de aprendizado de máquina e redes neurais profundas, esses algoritmos podem aprender com exemplos e aprimorar sua capacidade de reconhecer e classificar uma ampla variedade de condições dermatológicas.

A integração desses modelos de IA com plataformas de comunicação, como o bot do Telegram, representa um avanço significativo na acessibilidade aos cuidados dermatológicos. Ao oferecer uma interface familiar e acessível para a obtenção de diagnósticos dermatológicos, o projeto visa reduzir as barreiras de acesso à assistência médica, proporcionando uma resposta rápida e confiável aos usuários, independentemente de sua localização geográfica ou recursos disponíveis.

Dessa forma, o projeto não apenas visa desenvolver algoritmos de IA avançados para a identificação de doenças de pele, mas também busca transformar essa tecnologia em uma ferramenta prática e acessível para melhorar a saúde dermatológica em todo o mundo. A aplicação eficaz da inteligência artificial pode não apenas agilizar o processo de diagnóstico, mas também contribuir para uma maior precisão e eficiência no tratamento das doenças de pele, beneficiando assim a qualidade de vida dos pacientes e reduzindo a carga sobre os sistemas de saúde.

## **2 Objetivos**

### **2.1 Desenvolvimento de um Sistema de Inteligência Artificial Preciso e Eficiente**

O principal objetivo deste projeto é desenvolver um sistema de inteligência artificial (IA) robusto e altamente preciso capaz de identificar e classificar diversas doenças de pele a partir de imagens dermatológicas. O sistema será projetado para reconhecer e diferenciar condições como Ceratose Actínica, Dermatite Atópica, Verruga Seborreica, Dermatofibra, Nevo Melanocítico, Carcinoma de Células Escamosas e Lesão Vascular, garantindo uma análise detalhada e confiável.

### **2.2 Implementação de uma Interface Acessível via Telegram Bot**

Uma parte fundamental do projeto é a implementação de uma interface intuitiva e acessível por meio do Telegram Bot. Isso permitirá que os usuários enviem imagens de suas lesões cutâneas diretamente para o sistema de IA, facilitando o processo de análise e diagnóstico.

### **2.3 Integração com Algoritmos Avançados de Machine Learning e Deep Learning**

O sistema será integrado com algoritmos avançados de Machine Learning e Deep Learning, incluindo Redes Neurais Convolucionais (CNNs). Essa integração permitirá uma análise mais profunda e precisa das imagens dermatológicas, garantindo uma alta taxa de acerto no diagnóstico das doenças de pele.

### **2.4 Avaliação da Eficiência e Precisão do Sistema**

Serão conduzidos testes rigorosos para avaliar a eficácia e precisão do sistema de IA desenvolvido. Isso incluirá o uso de conjuntos de dados diversificados e a comparação dos resultados obtidos com diagnósticos realizados por dermatologistas especializados. O objetivo é garantir que o sistema seja altamente confiável e capaz de fornecer diagnósticos precisos em uma ampla gama de situações.

### **2.5 Contribuição para a Democratização dos Cuidados Dermatológicos**

Além de fornecer diagnósticos precisos e eficientes, o projeto visa contribuir para a democratização dos cuidados dermatológicos. Ao reduzir o tempo de espera para consultas e oferecer

uma avaliação preliminar rápida e confiável, especialmente em áreas com escassez de profissionais de saúde especializados, o sistema busca ampliar o acesso aos cuidados de saúde dermatológica, melhorando assim a qualidade de vida dos pacientes.

Por meio desses objetivos estruturados e abrangentes, o projeto visa não apenas desenvolver uma ferramenta eficaz de diagnóstico dermatológico, mas também torná-la acessível e útil para um público mais amplo, contribuindo assim para a melhoria da saúde dermatológica em escala global.

### **3 Referencial Teórico**

Para o desenvolvimento de um sistema de inteligência artificial (IA) voltado para o diagnóstico de doenças de pele, é essencial compreender os avanços recentes e as metodologias aplicadas em áreas correlatas, como a classificação de imagens médicas. Diversos estudos têm demonstrado a eficácia de modelos de deep learning para tarefas de diagnóstico automatizado, utilizando conjuntos de dados rotulados e técnicas de pré-processamento de imagens. A seguir, discutiremos alguns trabalhos relevantes na área.

#### **3.1 Modelos de Deep Learning para Diagnóstico Médico**

No trabalho de Bacellar et al. (2021), os autores utilizaram um total de 6432 imagens divididas em três categorias: Pulmões Normais, Pulmões com Pneumonia e Pulmões com Covid-19. O conjunto de dados foi separado em 80% para treinamento, 10% para teste e 10% para validação. Os autores compararam o desempenho de diversos modelos pré-treinados, incluindo ResNet, VGG, Inception e EfficientNet, com um modelo desenvolvido por eles, nomeado DLH-COVID (Deep Learning in Healthcare - COVID). Na etapa de validação, o modelo DLH-COVID apresentou uma acurácia de 95%, superando a maioria dos modelos comparados. Este estudo destaca a importância de utilizar modelos pré-treinados como base para o desenvolvimento de novos modelos específicos para tarefas médicas.

Zak e Krzyzak (2020) investigaram o uso de redes neurais para a classificação de imagens de raio-x pulmonares. Os pesquisadores utilizaram 918 imagens divididas igualmente entre três classes: pulmões com pneumonia, pulmões com tuberculose e pulmões saudáveis. Para melhorar a precisão, utilizaram o modelo MTANN (Massive Training Artificial Neural Network) para criar máscaras dos pulmões, facilitando o aprendizado dos modelos de redes neurais. Os modelos VGG16, ResNet-50 e InceptionV3 foram treinados e testados, alcançando acurácias

de 76%, 73% e 88%, respectivamente. Este trabalho demonstra a eficácia de técnicas de pré-processamento específicas, como a criação de máscaras, para melhorar o desempenho dos modelos.

Shamrat et al. (2023) desenvolveram um modelo baseado no MobileNetV2, chamado MobileLung NetV2, para a classificação de imagens de pulmões em 15 classes distintas, incluindo 14 doenças e uma classe saudável. Utilizaram um conjunto de dados com mais de 110 mil imagens, aplicando filtro Gaussiano para reduzir o ruído das imagens. Na fase de treinamento e testes, além do modelo criado, utilizaram cinco modelos pré-treinados: InceptionV3, AlexNet, DenseNet121, VGG19 e MobileNetV2, que obtiveram acurácias de 79,11%, 82,95%, 88,9%, 88,99% e 91,6%, respectivamente. O MobileLung NetV2 alcançou uma acurácia de 96%, demonstrando a importância de técnicas de redução de ruído e a eficácia de modelos especializados para tarefas específicas.

### **3.2 Aplicação de Redes Neurais Convolucionais em Diagnósticos Dermatológicos**

Baseando-se nos estudos mencionados, é evidente que as Redes Neurais Convolucionais (CNNs) têm se mostrado altamente eficazes para a análise de imagens médicas. A capacidade das CNNs de aprender representações hierárquicas de características visuais as torna ideais para tarefas de classificação de doenças de pele. Modelos pré-treinados como VGG16, ResNet, e Inception oferecem uma base sólida que pode ser adaptada para diagnósticos dermatológicos, proporcionando um ponto de partida eficiente e comprovado.

A utilização de técnicas de pré-processamento de imagens, como normalização, redimensionamento e aumento de dados, é crucial para garantir a qualidade e a variabilidade do conjunto de dados. Além disso, métodos específicos de tratamento de imagem, como a aplicação de filtros para redução de ruído, podem melhorar significativamente a precisão dos modelos.

### **3.3 Validação e Avaliação de Modelos**

A validação rigorosa dos modelos desenvolvidos é essencial para garantir sua eficácia e confiabilidade. A divisão do conjunto de dados em subsets de treinamento, validação e teste é uma prática comum que permite avaliar o desempenho do modelo em diferentes fases de desenvolvimento. Métricas de desempenho como acurácia, precisão, recall, F1-score e área sob a curva ROC são fundamentais para uma avaliação abrangente dos modelos.

Em conclusão, os estudos analisados fornecem uma base sólida para o desenvolvimento de



um sistema de IA para o diagnóstico de doenças de pele. A aplicação de CNNs, aliada a técnicas de pré-processamento e modelos pré-treinados, oferece um caminho promissor para alcançar diagnósticos precisos e eficientes. Além disso, a implementação de um sistema acessível via Telegram Bot pode democratizar o acesso aos cuidados dermatológicos, proporcionando benefícios significativos para a saúde pública.

Esses trabalhos relacionados oferecem um panorama das abordagens utilizadas em diagnósticos médicos automatizados e fornecem insights valiosos para o desenvolvimento de um sistema similar voltado para o diagnóstico de doenças de pele.

## 4 Metodologia

### 4.1 Descrição do conjunto de dados

Para treinar e testar nosso modelo de inteligência artificial, utilizaremos uma base de dados composta por imagens de diferentes doenças de pele, incluindo Ceratose Actínica, Dermatite Atópica, Verruga Seborreica, Dermatofibra, Nevo Melanocítico, Carcinoma de Células Escamosas e Lesão Vascular. Essas imagens serão obtidas de bancos de dados públicos, como o *International Skin Imaging Collaboration (ISIC)* e o *National Institutes of Health (NIH)*. Cada imagem será devidamente rotulada com a categoria de doença correspondente para fins de treinamento e avaliação do modelo.

### 4.2 Pré-processamento de dados

As etapas de pré-processamento de dados incluirão a normalização das imagens para uma escala de valores adequada, redimensionamento para uma resolução padronizada, e, se necessário, correção de distorções e ajustes de contraste. Além disso, serão aplicadas técnicas de aumento de dados, como rotação, espelhamento e alteração de brilho, para aumentar a variabilidade do conjunto de dados e melhorar a robustez do modelo.

### 4.3 Desenvolvimento de Modelos

O desenvolvimento do sistema de IA envolve várias etapas, como descrito a seguir:

- **Divisão do Conjunto de Dados:** O conjunto de dados será dividido em três subsets: treino (70%), validação (20%) e teste (10%).

- **Escolha dos Algoritmos:** Serão utilizadas Redes Neurais Convolucionais (CNNs) devido à sua eficácia em tarefas de reconhecimento de imagem. Modelos pré-treinados, como VGG16, ResNet e Inception, serão considerados para melhorar a precisão e eficiência do sistema.
- **Treinamento do Modelo:** O modelo será treinado utilizando o subset de treino. Durante o treinamento, serão ajustados hiperparâmetros como taxa de aprendizado, número de camadas e neurônios, entre outros.

#### 4.4 Escolha e justificativa dos algoritmos

Para este estudo, optaremos por utilizar algoritmos de *Deep Learning*, especificamente Redes Neurais Convolucionais (*Convolutional Neural Networks* - CNNs). As CNNs têm se mostrado altamente eficazes na análise de imagens devido à sua capacidade de aprender representações hierárquicas de características visuais. Além disso, modelos pré-treinados, como o VGG16, ResNet e Inception, serão considerados devido ao seu desempenho comprovado em tarefas de classificação de imagens médicas.

#### 4.5 Avaliação do modelo

A eficácia do modelo será avaliada por meio de métricas de desempenho, como precisão, sensibilidade, especificidade e área sob a curva ROC (Receiver Operating Characteristic). Além disso, serão utilizadas técnicas de validação cruzada para garantir a generalização do modelo em diferentes conjuntos de dados. A interpretação dos resultados será realizada em teste de ambiente, comparando as classificações do modelo com diagnósticos clínicos.

#### 4.6 Implementação do Telegram Bot

Para facilitar o acesso ao sistema de diagnóstico, será implementada uma interface via Telegram Bot. Os passos incluem:

- **Configuração do Bot:** Criação e configuração do bot na plataforma Telegram.
- **Integração com o Modelo de IA:** Desenvolvimento de um backend em Python para integrar o modelo de IA com o bot. O backend permitirá a análise das imagens enviadas pelos usuários e fornecerá diagnósticos preliminares.

- **Testes e Validação:** Testes serão realizados para garantir que o bot funcione corretamente. Serão realizadas avaliações contínuas para garantir a precisão e confiabilidade do sistema.

| Atividades                                      | Agosto | Setembro | Outubro | Novembro | Dezembro |
|---|--------|----------|---------|----------|----------|
| Pesquisa de Ferramentas e Tecnologias           | X      | X        |         |          |          |
| Implementação do Bot no Telegram                |        | X        | X       |          |          |
| Desenvolvimento da IA                           |        |          | X       | X        |          |
| Integração da IA com o Bot                      |        |          |         | X        |          |
| Testes e Ajustes                                |        |          |         | X        | X        |
| Documentação do Desenvolvimento e Implementação |        |          |         | X        | X        |
| Análise e Interpretação dos Resultados          |        |          |         |          | X        |
| Preparação do Relatório Final                   |        |          |         |          | X        |

Figura 1: Cronograma de execução de atividades.

## Referências

- [Brinker et al. 2018]BRINKER, T. J. et al. Deep learning outperformed 136 of 157 dermatologists in a head-to-head dermoscopic melanoma image classification task. *European Journal of Cancer*, v. 103, p. 114–121, 2018.
- [Esteva et al. 2017]ESTEVA, A. et al. Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, v. 542, n. 7639, p. 115–118, 2017.
- [Goldsmith et al. 2012]GOLDSMITH, L. A. et al. *Fitzpatrick's Dermatology in General Medicine*. 8. ed. [S.l.]: McGraw Hill Professional, 2012.
- [4]GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. [S.l.]: MIT Press, 2016.
- [Haenssle et al. 2018]HAENSSLE, H. A. et al. Man against machine: diagnostic performance of a deep learning convolutional neural network for dermoscopic melanoma recognition in comparison to 58 dermatologists. *Annals of Oncology*, v. 29, n. 8, p. 1836–1842, 2018.
- [6]LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, n. 7553, p. 436–444, 2015.
- [7]MARGHOOB, A. A.; BRAUN, R. P.; KOPF, A. W. *Dermoscopy: The Essentials*. [S.l.]: Elsevier, 2017.
- [8]NARLA, A.; PATEL, R.; JONMICHAEL, H. Dermbot: A chatbot for early detection of skin cancer using deep learning. *arXiv preprint arXiv:2004.03801*, 2020.
- [9]NóbREGA, M. M.; SILVA, G. D.; NASCIMENTO, L. F. C. Diagnóstico das principais dermatoses comuns em clínica geral. *Anais Brasileiros de Dermatologia*, v. 84, n. 3, p. 257–270, 2009.
- [Rajpurkar et al. 2017]RAJPURKAR, P. et al. Chexnet: Radiologist-level pneumonia detection on chest x-rays with deep learning. *arXiv preprint arXiv:1711.05225*, 2017.
- [Tschandl et al. 2019]TSCHANDL, P. et al. Human-computer collaboration for skin cancer recognition. *Nature Medicine*, v. 25, n. 8, p. 1215–1218, 2019.